

# Compressão de Dados e Teoria da Informação

Lucas Silva Amorim



Universidade Federal do ABC

**Título:** Compressão de Dados e Teoria da Informação

**Autor:** Lucas Silva Amorim

**Orientador:** Prof<sup>a</sup> Dr.<sup>a</sup> Cristiane M. Sato

Trabalho de conclusão de curso apresentado como requisito parcial para obtenção do título de Bacharel em Ciências da Computação pela Universidade Federal do ABC.

**Banca Examinadora:**

**Prof. Dr. Circulando de Souza**

Universidade Federal de ..

**Prof. Dr. Recirculando de Souza**

Universidade Federal de ..

Santo André, 30 de agosto de 2022.

<b>1</b>	<b>Introdução</b>	<b>7</b>
<b>2</b>	<b>Conceitos e definições fundamentais</b>	<b>8</b>
2.1	Código . . . . .	8
2.1.1	Códigos unicamente decodificáveis e livres de prefixo . . . . .	8
2.2	Relações fundamentais com a Teoria da Informação . . . . .	9

Opcional. Agradeço a todos os que me ajudaram na elaboração deste trabalho...

Neste lugar vai um resumo do projeto e objetivos, apresentando os principais resultados;

Conforme as normas NBR 14724:2002 da ABNT, o resumo é elemento obrigatório, constituído de uma seqüência de frases concisas e objetivas e não de uma simples enumeração de tópicos, não ultrapassando 500 palavras, seguido, logo abaixo, das palavras representativas do conteúdo do trabalho, isto é, palavras-chave e/ou descritores.

**Palavras Chaves:** TCC, Trabalho, Modelo

Versão em língua estrangeira do resumo. Obrigatório, pela ABNT. O título é ABSTRACT, em inglês, RESUMEN, em espanhol castelhano, e RÉSUMÉ, em francês. Sugerimos Inglês.

**Keywords:** aubergine,carrot, radish

Esta pesquisa pretende mostrar que [ ... ] através de [ ... ] conforme concepções apresentadas por [ ... ] . Para isso, articulamos o conceito de [ ... ] com o conceito de [ ... ] . Fizemos pesquisas de recepção conforme [ ... ] . Articulamos os resultados a partir de idéias de [ ... ] . “Neste primeiro parágrafo você deve deixar completamente claro o que pretende com o trabalho. A introdução é redigida depois de escrito todo o trabalho porque, no decorrer da pesquisa, algumas coisas podem ser modificadas em relação ao projeto original”. “Depois, em vários parágrafos, você deve falar sobre a problematização, a contextualização histórica, a revisão bibliográfica, os objetivos, a justificativa, a metodologia. As conclusões, evidentemente, devem ficar no capítulo Considerações Finais, para que o leitor não perca o interesse pelo seu trabalho ?. Toda a introdução é feita sem subtítulos, em texto normal”.

## 2 CONCEITOS E DEFINIÇÕES FUNDAMENTAIS

Este capítulo apresenta algumas definições e conceitos fundamentais para o entendimento das técnicas de compressão que serão discutidas em capítulos posteriores.

### 2.1 Código

Um **código**  $C$  mapeia uma **mensagem**  $m \in M$  para uma cadeia de **palavras código** em  $W^+$ , onde  $M$  é chamado **alfabeto de origem** e  $W^+$  **alfabeto de palavras código**. Vamos utilizar a notação  $A^+$  para se referir ao conjunto que contém todas as cadeias de  $A$ , isto é,  $A^+ = \bigcup_{i \geq 1} A^i : A^i = (a_1, \dots, a_i), a \in A$ . Deste modo, podemos representar um código como uma função  $C : M \rightarrow W^+$ .

Os elementos dos alfabetos de origem e de palavras código podem ter um comprimento fixo ou variável. Códigos nos quais os alfabetos possuem um comprimento fixo são chamados de **códigos de comprimento fixo**, enquanto os que possuem alfabetos de comprimento variáveis são chamados **códigos de comprimento variável**. Provavelmente o exemplo mais conhecido de código de comprimento fixo seja código ASCII, que mapeia 64 símbolos alfa-númericos (ou 256 em sua versão estendida) para palavras código de 8 bits. Todavia, a compressão de dados utiliza apenas códigos de comprimento variável, mas especificamente códigos que variam o comprimento de acordo com a probabilidade associada à mensagem (o tema será melhor detalhado em seções posteriores).

#### 2.1.1 Códigos unicamente decodificáveis e livres de prefixo

Um código é **distinto** se pode ser representado como uma função **bijetora**, i.e.,  $\forall m_1, m_2 \in M, C(m_1) \neq C(m_2)$ . Um código é dito **unicamente decodificável** quando  $C(m) = w^n \Leftrightarrow C^{-1}(w^n) = m$ , com  $m \in M$  e  $w^n \in W^+$ .

Vamos definir  $C^+$  como a **codificação** correspondente ao código  $C$ , tal que  $C^+(m^n) = C(m_1)C(m_2)\dots C(m_n) : m^n = m_1 m_2 \dots m_n$ , isto é  $C^+ : M^+ \rightarrow W^+$ . A função de **decodificação**  $D^+ : W^+ \rightarrow M^+$  se refere a operação inversa da codificação, de modo que dado um código **unicamente decodificável**  $C$ ,  $D^+(C^+(m^n)) = m^n$ .



Um **código livre de prefixo** é um código  $C'$  em que  $\nexists w_1^n, w_2^n \in W^+ \mid w_1^n$  é **prefixo** de  $w_2^n$ , por exemplo, o conjunto de palavras código  $W^+ := \{1, 01, 000, 001\}$  não possui nenhuma cadeia que é prefixo de outra dentro do conjunto. Códigos livres de prefixo podem ser *decodificados instantaneamente*, isto é, podemos decodificar uma palavra código sem precisar verificar o início da seguinte.

**Teorema 2.1** *Todo código livre de prefixo é unicamente decodificável.*

**Demonstração:** Seja  $C$  um código livre de prefixo e  $S_n = s_1 \dots s_n$  uma mensagem codificada por  $C$ . Vamos provar por indução que o teorema é verdadeiro para todo  $n \in \mathbb{Z}^+$

**Casos base:** Quando  $n = 1$ , a mensagem  $S$  só possui uma palavra código, logo é unicamente decodificável. Se  $n = 2$ , então  $S$  possui uma palavra código  $s_1$  que não pode ser prefixo de  $s_2$  (pela própria definição de códigos livres de prefixo), o que claramente significa que  $S$  é unicamente decodificável.

**Passo indutivo:** Seja  $k \in \mathbb{Z}^+$ , e suponha por hipótese de indução que o teorema vale para  $n \leq k$ . Como  $S_{k+1}$  é livre de prefixo, existe um prefixo de  $S_{k+1}$ ,  $S_j = s_1 \dots s_j$  (com  $j \leq k + 1$ ) que é unicamente decodificável (dado que ela não pode ser prefixo de nenhuma outra). a mensagem  $S'_{k+1} = s_{j+1} \dots s_{k+1}$  ainda é uma concatenação decodificável e  $|S'_{k+1}| \leq |S_{k+1}|$ , o que significa que por hipótese de indução  $S'_{k+1}$  é unicamente decodificável. Como  $S_{k+1} = S_j S'_{k+1}$ , segue que  $S_{k+1}$  é unicamente decodificável.  $\square$

## 2.2 Relações fundamentais com a Teoria da Informação

A codificação é comumente dividida em duas componenets diferentes: *modelo* e *codificador*. O *modelo* identifica a distribuição de probabilidade das mensagens baseado em sua semântica e estrutura. O *codificador* toma vantagem de um possível *bias* apontado pela modelagem, e usa uma estratégia gulosa em relação a probabilidade associada às mensagens para reduzir seu tamanho. (substituindo as mensagens que ocorrem com maior frequência por símbolos menores).

Desta forma, é evidente que os algoritmos de compressão sempre devem tomar vantagem de alguma distribuição de probabilidades "desbalanceada" sobre as mensagens para efetivamente reduzir o tamanho destas, ou seja, a compressão é fortemente relacionada com a probabilidade. Nesta seção, vamos construir o embasamento teórico necessário para entender a relação entre as probabilidades associadas e o comprimento das mensagens, e consequentemente criar uma noção dos parâmetros que devem ser maximizados para alcançar uma codificação eficiente.

## REFERÊNCIAS BIBLIOGRÁFICAS

- [HL] HIRSCHBERG, D.S; LELEWER D.A; *Data compression*, Computing Surveys 19.3, 1987.
- [Ble] BLELLOCH G.E; *Introduction to Data Compression*, Carnegie Mellon, 2013
- [BT] BERTSEKAS D.P; TSITSIKLIS J.N; *Introduction to Probability* M.I.T, Lecture Notes Course 6.041-6.431, 2000